La IA no se acuerda. Relee.

Contexto, tokens y compactación: por qué se le olvidan las cosas y por qué se les acaba el cupo.

Con

Carlos René Angarita Sanguino

Elian Camilo Angarita Sanguino

Primero, la tarea. ¿Cómo les fue con su archivo de reglas?

01 Una vez en que la IA no respetó una regla.

02 Algo que tuvieron que repetirle a mano.

Anotamos los casos. Varios se explican hoy.

Pregunta 1

En una conversación larga, ¿la IA empezó a responder peor o se le olvidó algo del principio?

Pregunta 2

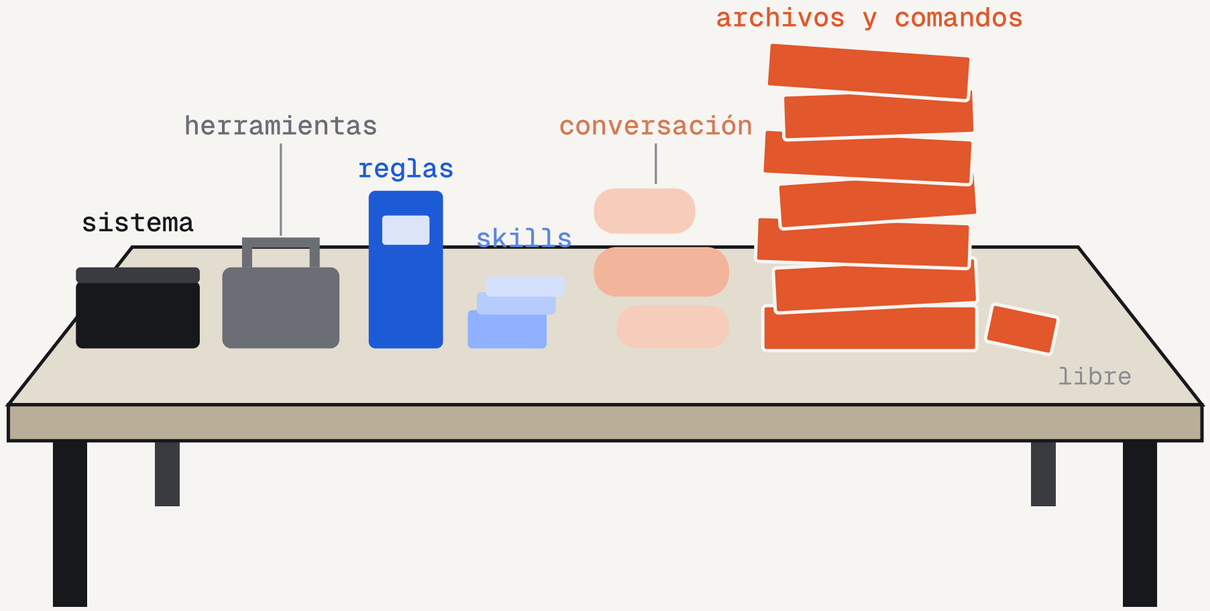
¿Alguien se ha quedado sin uso de Claude a mitad del día?

Las dos tienen la misma causa.

El contexto es la mesa de trabajo de la IA.

Todo lo que "sabe" en una conversación está encima de esa mesa.
Y la mesa tiene tamaño fijo.

¿Qué hay encima de la mesa?

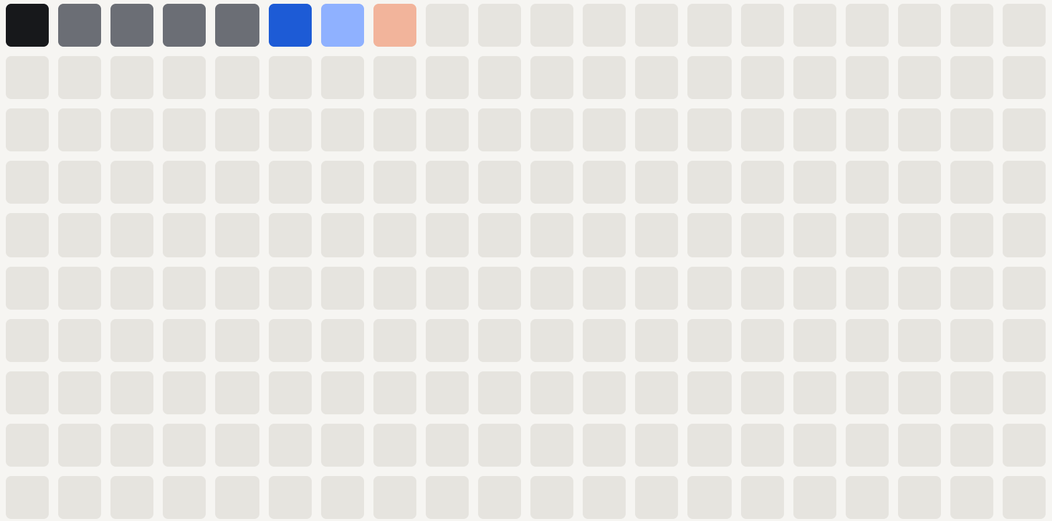


- **Lo fijo.** Sus instrucciones y herramientas, su archivo de reglas completo y la descripción de cada skill.
- **La conversación.** Lo que ustedes escriben y lo que ella responde.
- **Lo que lee y corre.** Cada archivo que abrió y cada salida de comando. **Esto es lo que más llena.**

Demo: /context muestra la mesa.

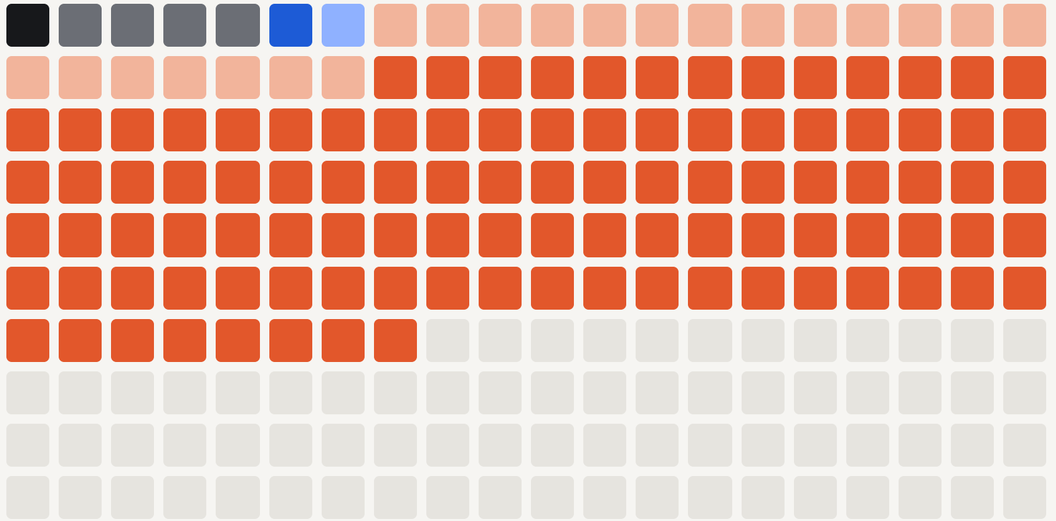
Sesión nueva

40k / 1M



Sesión de todo el día

640k / 1M



sistema · herramientas · reglas · skills · conversación · archivos y comandos

Ventana de 1M. Cada cuadro, unos 5.000 tokens. Números de ejemplo.

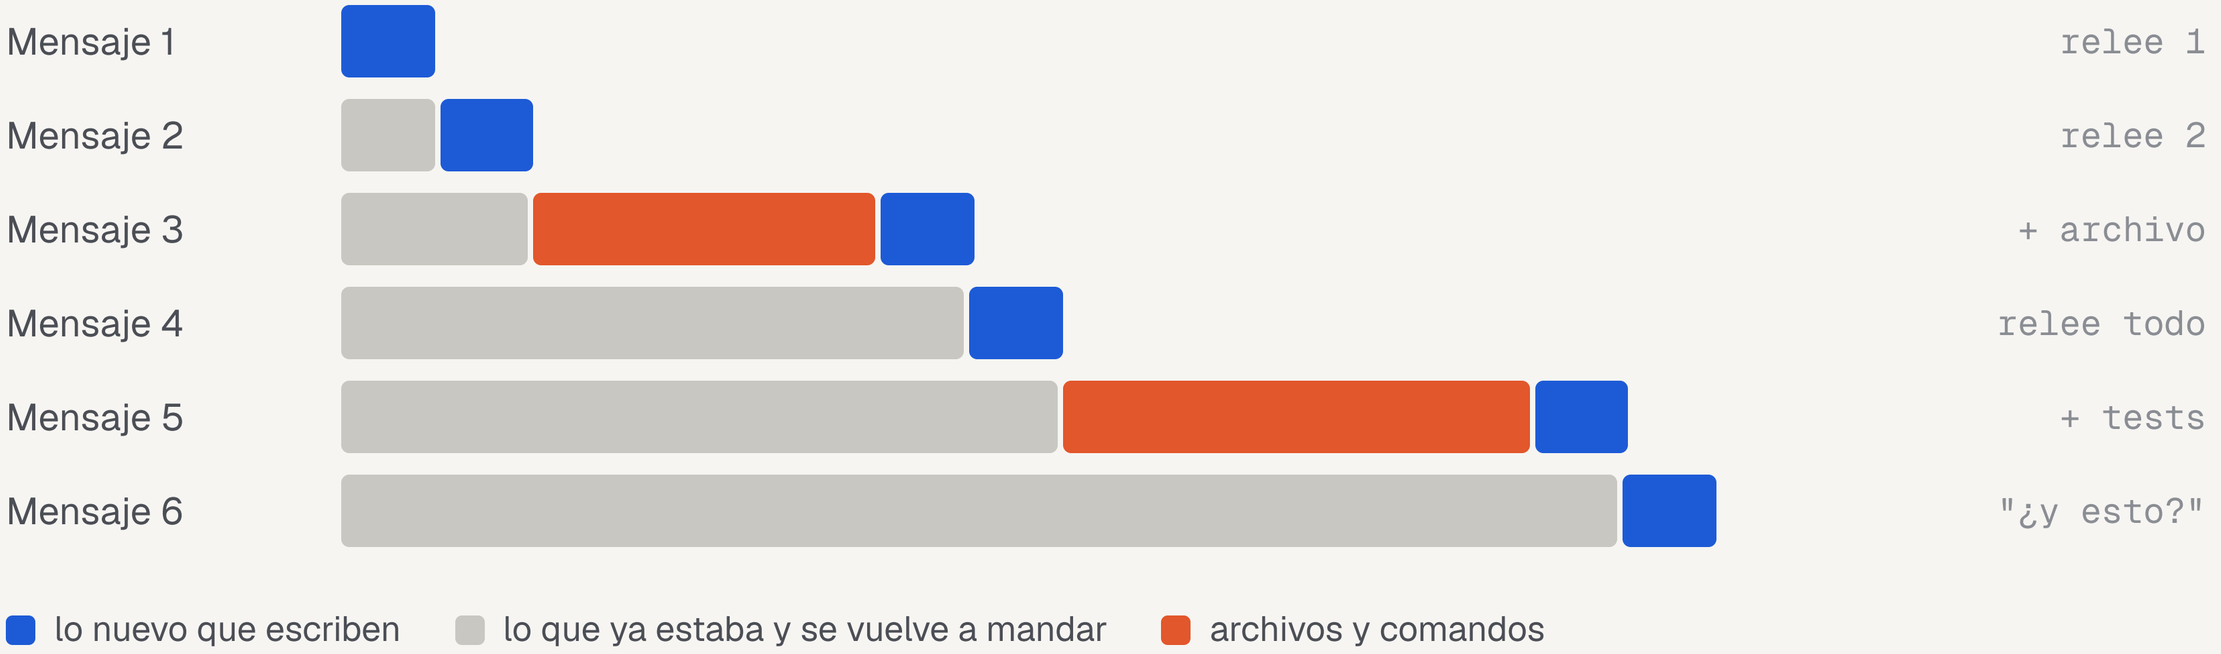
No escribimos casi nada. La mesa se llenó con lo que la IA leyó y ejecutó.

El token: la unidad en que se mide (y se cobra) el texto.

`Agre` `ga` `valid` `ación` `al` `formul` `ario`

≈	Un pedazo de palabra, más o menos. Esta frase son unos 7 tokens.
es	El español suele gastar algo más que el inglés para decir lo mismo.

En cada mensaje, la herramienta le manda toda la conversación otra vez.



Una pregunta de una línea, en una sesión de todo el día, cuesta como toda la sesión.

Hay caché, que abarata releer lo mismo. Pero sigue contando, y si dejan la sesión quieta un rato largo, se enfría y el siguiente mensaje reprocesa todo.

Con licencia no pagan por token. Gastan cupo.

claude.ai **Chat**
preguntas, documentos

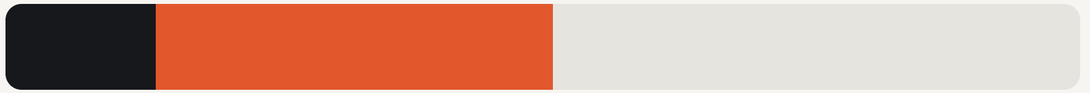
claude **Claude Code**
lee archivos, corre comandos

En los planes de equipo, **es el mismo cupo**.

Ventana de 5 horas — se renueva



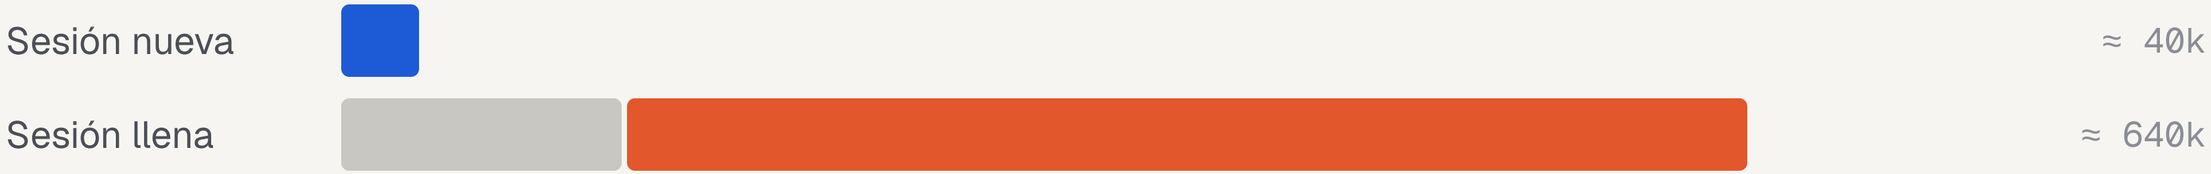
Ventana semanal — se renueva



Según Anthropic, una sesión de depuración en Claude Code puede gastar más que un día entero de chat.

Demo: la misma pregunta, en dos sesiones.

> ¿Qué hace la función `totalPorCategoria`?



La respuesta es igual. El consumo, no.

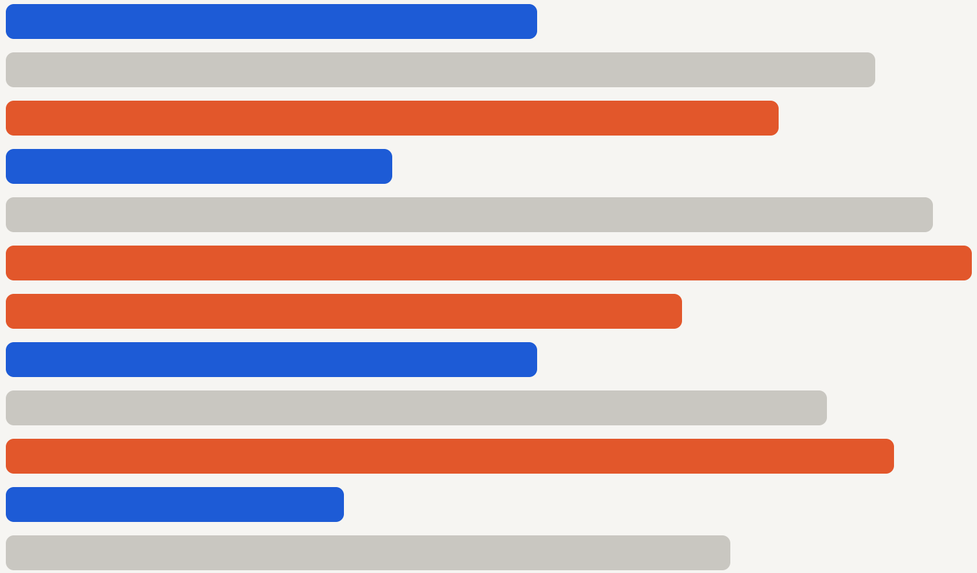
/usage: qué les está gastando el cupo.

1. Las barras de su ventana de 5 horas y de la semana.
2. Qué es lo que más les está gastando el cupo.
3. Recomendaciones concretas, como recortar el archivo de reglas.

La mesa ahora es de 1M. Mucho antes de llenarse, la IA ya rinde peor.

Con tanto encima se distrae y pierde de vista lo del principio. Por eso "se le olvidan" las reglas en conversaciones largas. Y una mesa más grande también es más para releer en cada mensaje.

Compactar: resumir lo anterior para hacer espacio.



→

Resumen

Se agregó validación al formulario.

Los tests pasan.

~~La ruta exacta del archivo que tocaron~~

~~Por qué descartaron la otra opción~~

Claude Code lo hace solo cuando la conversación se acerca al límite. Es un resumen: **se pierden detalles**.

¿Siguen con lo mismo, o cambian de tarea?

Sigo con lo mismo

`/compact`

`petición grande`

Resume la conversación. Pueden decirle qué conservar:

```
/compact conserva los cambios de código y los resultados de los tests
```

Cambio de tarea

`/clear`

`gratis`

Arranca de cero. La mesa queda limpia.

Para compactar, la IA tiene que leer toda la conversación. Limpiar no le cuesta nada.

`/clear` no borra: la anterior queda en `/resume`. Con `/rename` le ponen nombre.

Demo: compactar y limpiar.

1. `/compact conserva los cambios de código` en la sesión llena.
2. Preguntarle un detalle del principio. ¿Lo conservó?
3. `/clear` y `/context`: la mesa volvió a estar limpia.

Seis hábitos para no llenar la mesa.

01

Una tarea por conversación

¿Cambian de tema? `/clear`.

02

Pedidos específicos

"Mejora el código" lee todo el repo. "Agrega validación al formulario de `App.tsx`" lee un archivo.

03

Nada de logs enteros

Peguen el error, no las 2.000 líneas.

04

Reglas cortas

Entran en cada mensaje. Menos de 200 líneas; lo especializado va a una skill.

05

Cortar a tiempo

¿Va por mal camino? `Esc` y corregir, o `/rewind` para volver a un mensaje anterior.

06

Delegar lo ruidoso

Tests o documentación en un subagente: el ruido se queda allá. Sesión 4.

20 minutos, en su sesión real.

1. Abran su conversación más larga y corran `/context`. ¿Qué ocupa más?
2. Abran `/usage`: desglose y recomendaciones.
3. Apliquen un arreglo: `/clear`, recortar sus reglas o apagar un MCP que no usen (`/mcp`).
4. Corran `/context` otra vez y comparen.

¿No usan Claude Code? La regla es la misma.

PARA	CLAUDE CODE	CHAT DE CLAUDE (CLAUDE.AI)
Ver el contexto	`/context`	la conversación entera es el contexto
Ver el consumo	`/usage`	Configuración › Uso
Arrancar limpio	**`/clear`**	**Nueva conversación**
Resumir	`/compact`	no aplica

Un chat de semanas sobre todo lo que se les ocurre es la sesión llena. Una conversación por tema.

Para la próxima: dos hábitos.

01 `/clear` cada vez que cambien de tarea.

02 El viernes, abran `/usage` y anoten qué les gastó más el cupo.

Próxima sesión: darle a la IA un plan claro antes de que escriba código, para que no tenga que adivinar.